


Name: 李桂欽 ID: R04725050 Department: 資訊管理 碩一 Homework: 4

Programming Assignment 4:

Programming Assignment 4 (1/2)

- **HAC clustering:**
 - Text collection:
 - The 1095 news documents.
 - $K = 8, 13, \text{ and } 20$.
 - Save each clustering result in a file – $K.txt$ (that is, 8.txt, 13.txt, and 20.txt).



Programming Assignment 4 (2/2)

- TA will evaluate your clustering performances in terms of *precision*, *recall*, and F_1 metrics.
- Note:
 - Documents are represented as **normalized tf-idf** vectors.
 - Remind your programming assignment 2.
 - **Cosine similarity** for pair-wise document similarity.
 - Similarity measure between clusters can be:
 - single-link, complete-link, group-average, and centroid similarity.
 - To speed up your clustering ..., you **MAY** ... (15 bonus points)
 - Use HEAP to obtain the cluster pair with maximal similarity.
 - Update cluster pair similarity in constant time.
- Please zip and submit ¹your clustering results ($K.txt$), ²source code, and ³a report to TA.
 - 3 weeks to complete, that is, **2016/1/19**.

My program result:

Step1: 部署 Hw4(將程式文檔放在 PHP 運行環境下)

Step2: 在瀏覽器輸入 <http://localhost/IR/SearchService.php>

生成的 Result 文檔，詳見 program_result 檔夾

My program architecture:

File Name	Date	Type	Size
origin_file	2015/12/26 12:41	文件夹	
program_result	2015/12/26 14:22	文件夹	
stop_words	2015/12/26 12:41	文件夹	
Cluster.php	2015/12/27 14:28	PHP 文件	5 KB
IRService.php	2015/12/26 15:21	PHP 文件	39 KB
PorterStemmer.php	2015/9/26 14:56	PHP 文件	14 KB
SearchService.php	2015/12/27 13:57	PHP 文件	1 KB

將要測試的文件 (1...1095) 放入到該文件夾下

程式執行結束之後，生成的結果文件會放在該文件夾下

設置stopword的文件夾，在文件夾下有多重語言版本的stopword list

Cluster 類文件是hw4的核心類文件，採用centroid clustering 算法，並且採用了 priority queue

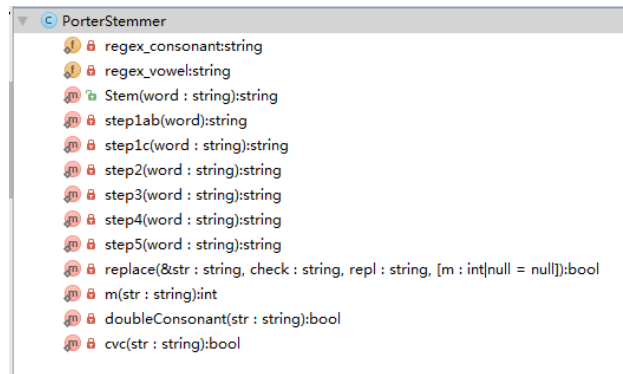
IRService 類文件是IR的核心文件，包含IR的諸多核心函數，如計算文章的TFIDF

PorterStemmer類文件採用porter的stem算法，對token進行處理

SearchService文件是系統的入口文件，執行該文件就會運行程式，輸出結果

My program main class:

PorterStemmer Class Structure:



演算法實現過程：

第一步，處理複數，以及 ed 和 ing 結束的單詞。

第二步，如果單詞中包含母音，並且以 y 結尾，將 y 改為 i。

第三步，將雙尾碼的單詞映射為單尾碼。

第四步，處理 -ic-, -full, -ness 等等尾碼。

第五步，在 <c>vcvc<v> 情形下，去除 -ant, -ence 等尾碼。

第六步，也就是最後一步，在 $m() > 1$ 的情況下，移除末尾的 “e”。

演算法使用說明：

傳入的單詞必須是小寫

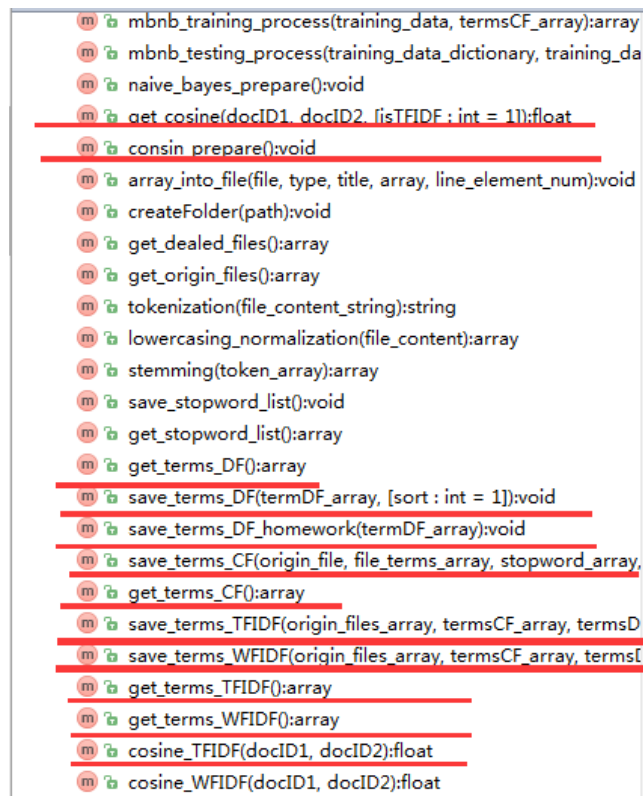
參考學習網站：

<http://tartarus.org/~martin/PorterStemmer/>

<http://snowball.tartarus.org/algorithms/english/stemmer.html>

<http://blog.csdn.net/noobzc1/article/details/8902881>

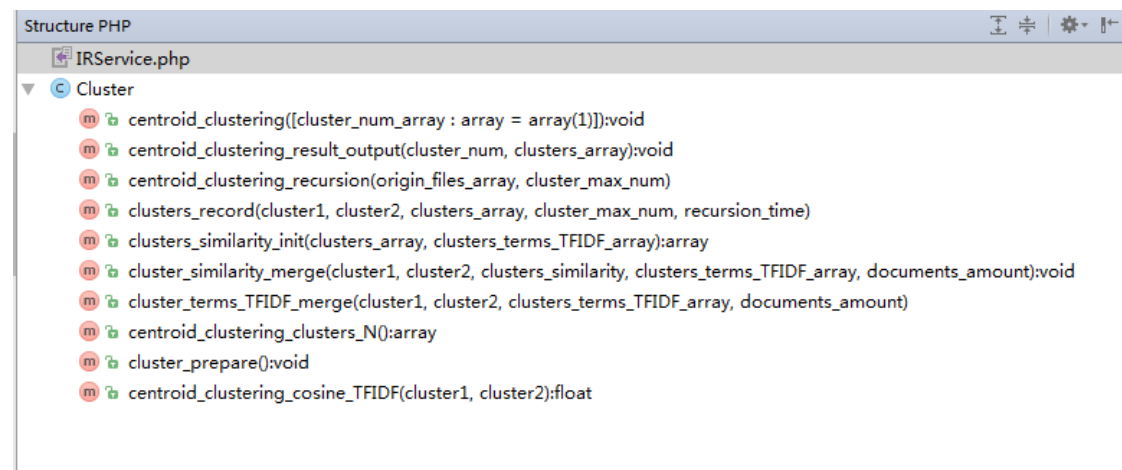
IRService Class Structure:



類的主要函數：

```
/*
 * 计算指定的两篇文章的相似度
 */
public function get_cosine()
/*
 * 计算文章相似度的前期工作
 */
public function consin_prepare()
/*
 * 计算出每个文件每个特异单词的 TF-IDF，并且保存在 TXT 文件中
 */
public function save_terms_TFIDF()
```

Cluster Class Structure:



類的主要函數：

```
class Cluster {
    // centroid clustering
    public function centroid_clustering( $cluster_num_array=array(1)) {...}
    //按照指定格式将centroid clustering 的结果输出到指定文件夹下
    public function centroid_clustering_result_output( $cluster_num,$clusters_array) {...}
    /*
    * centroid clustering 的循环处理过程
    * centroid clustering 的初始化处理，生成 N 篇文章即为N个cluster的原始cluster数组，N个cluster的terms_TFIDF数组，N个cluster两两之间的相似度数组
    * centroid clustering 的循环处理，依次得到cluster数组，cluster的terms_TFIDF数组，cluster两两之间的相似度数组
    * centroid clustering 最后结果，得到N、N-1、N-2...1个cluster
    */
    public function centroid_clustering_recursion($origin_files_array,$cluster_max_num){...}
    //记录centroid clustering 处理过程中生成的N、N-1、N-2...1个cluster所拥有的document id
    public function clusters_record($cluster1,$cluster2,$clusters_array,$cluster_max_num,$recursion_time){...}
    //计算两两文章的相似度，为合并文章，形成新的cluster提供依据
    public function clusters_similarity_init($clusters_array,$clusters_terms_TFIDF_array){...}
    //根据相似度，合并文章/cluster
    public function cluster_similarity_merge($cluster1,$cluster2, $clusters_similarity,$clusters_terms_TFIDF_array,$documents_amount){...}
    //合并文章/cluster的terms_TFIDF情况
    public function cluster_terms_TFIDF_merge($cluster1,$cluster2,$clusters_terms_TFIDF_array,$documents_amount){...}
    //将N篇文章转化为N个cluster（附带cluster对应的document id 以及 document numbers）
    public function centroid_clustering_clusters_N(){...}

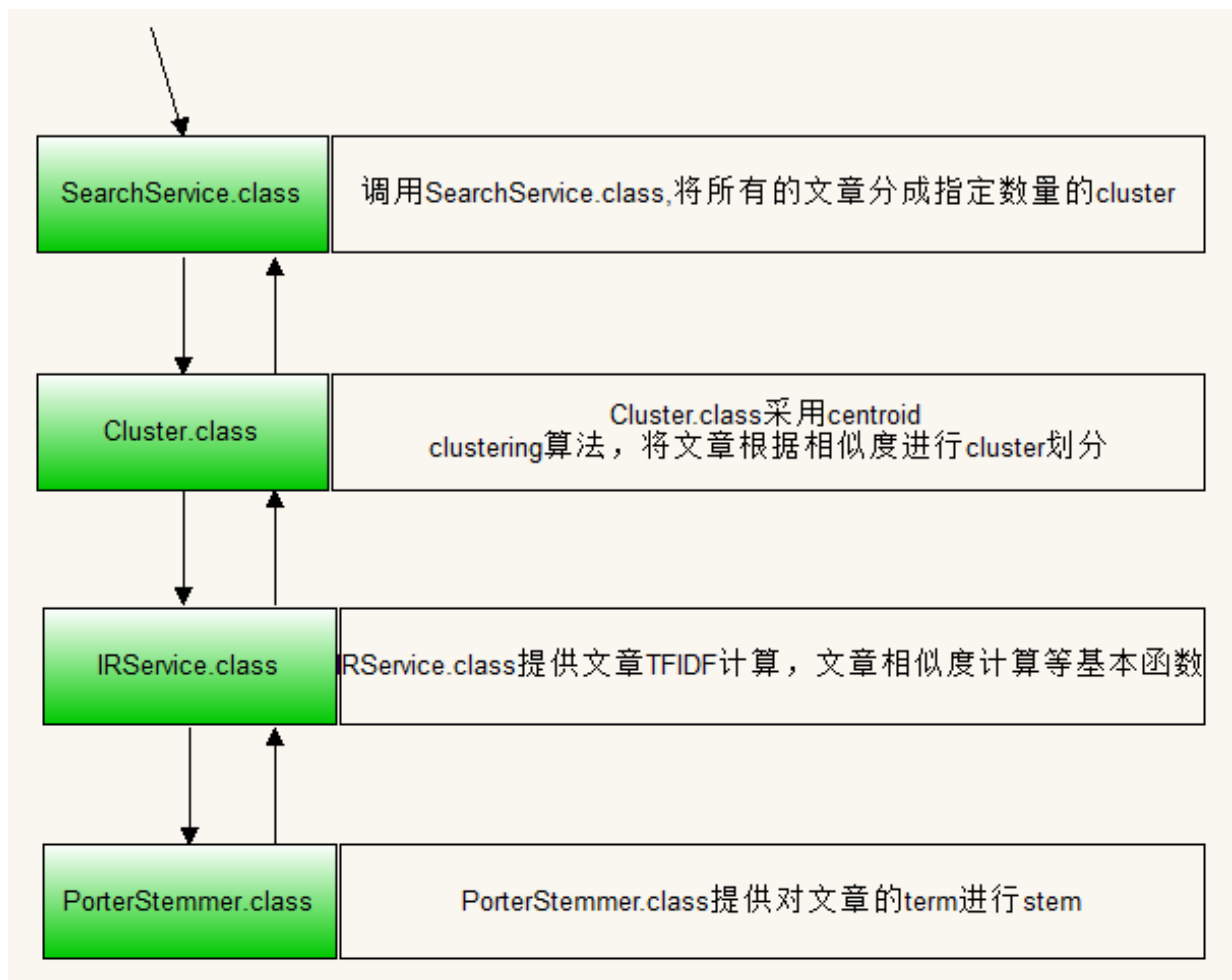
    public function cluster_prepare(){...}
    // 计算出两个cluster的中心点相似度
    public function centroid_clustering_cosine_TFIDF($cluster1,$cluster2){...}
}
```

Use HEAP to obtain the cluster pair with maximal similarity. 說明

```
//根据相似度，合并文章/cluster
public function cluster_similarity_merge($cluster1,$cluster2, $clusters_similarity,$clusters_terms_TFIDF_array,$documents_amount){
    // var_dump(count($clusters_similarity));
    unset($clusters_similarity[$cluster1]);
    unset($clusters_similarity[$cluster2]);
    $clusters_similarity_top= array();
    foreach($clusters_similarity as $elements_key =>$elements_value){
        //var_dump(count($clusters_similarity[$elements_key]));
        unset($clusters_similarity[$elements_key][$cluster1]);
        unset($clusters_similarity[$elements_key][$cluster2]);
        $clusters_similarity[$elements_key][$cluster1+$documents_amount] =$this->centroid_clustering_cosine_TFIDF($clusters_terms_TFIDF_array[$cluster1+$documents_amount],$clusters_ter
        arsort($clusters_similarity[$elements_key]);
        $clusters_similarity_top[$elements_key]= current(array_keys($clusters_similarity[$elements_key]))= current(array_values($clusters_similarity[$elements_key]));
        //var_dump(count($clusters_similarity[$elements_key]));
    }
    // var_dump(count($clusters_similarity));
    arsort($clusters_similarity_top);
    list($cluster_left, $cluster_right) =explode('=', current(array_keys($clusters_similarity_top)));
    // var_dump($cluster_left);
    // var_dump($cluster_right);
    // var_dump($clusters_similarity);
    return array(
        'cluster1' => $cluster_left,
        'cluster2' => $cluster_right,
        'clusters_similarity'=>$clusters_similarity
    );
}
```

Heap 在PHP中不属于本身自有的数据结构，需要自己定义，而这里与Heap的按照大小自动调整，生成Priority queue（Heap）的效果一样。
【也就是将普通数据转成按照一定有序的数组】

多個 Class 的工作協調過程:



Clustering work flow

